

**UNIVERZITA PAVLA JOZEFA ŠAFÁRIKA V KOŠICIACH**  
**PRÍRODOVEDECKÁ FAKULTA**

**RIADENIE SW PRODUKTOV POMOCOU HCI**  
**KOMPONENTOV**

**Diplomová práca**

Študijný program:	Informatika
Študijný odbor:	9.2.1. - informatika
Školiace pracovisko:	Ústav informatiky
Vedúci práce:	doc. RNDr. Gabriel S e m a n i š i n, PhD.
Konzultanti:	Ing. Viktor Michalčín, PhD., Matúš Kirchmeyer

# Obsah

<b>1</b>	<b>Zoznam použitých skratiek</b>	<b>3</b>
<b>2</b>	<b>Teoretický prehľad</b>	<b>4</b>
2.1	Human-Computer Interaction . . . . .	4
2.2	Vývoj HCI . . . . .	4
2.2.1	CLI . . . . .	4
2.2.2	GUI . . . . .	5
2.2.3	NUI . . . . .	5
<b>3</b>	<b>Motivácia a ciele</b>	<b>7</b>
<b>4</b>	<b>Riešenia VAD</b>	<b>8</b>
<b>5</b>	<b>Návrh riešenia</b>	<b>12</b>
5.1	Detekcia bodov na tvári - VVAD . . . . .	12
5.2	Existujúce implementácie . . . . .	14
5.2.1	Intel RealSense . . . . .	14
5.2.2	Knižnica OpenCV . . . . .	15
5.2.3	Knižnica Dlib . . . . .	16
5.2.4	Porovnanie knižníc OpenCV a Dlib . . . . .	16
5.3	Detekcia reči zo zvuku - AVAD . . . . .	19
5.4	VAD spojením AVAD a VVAD a vytvorenie knižnice . . . . .	20
<b>6</b>	<b>Implementácia a testovanie</b>	<b>21</b>
6.1	Použitý hardware a software . . . . .	21
6.2	Implementácia VVAD . . . . .	21
6.2.1	Metóda <code>Frame</code> . . . . .	22
6.2.2	VVAD . . . . .	23
6.3	Implementácia AVAD . . . . .	26
	<b>Zoznam použitej literatúry</b>	<b>27</b>

# 1 Zoznam použitých skratiek

AVAD - Acoustic Voice Activity Detection

CLI - Command-Line Interface

CNN - Convolutional neural network

DCNN - Deep convolutional neural network

DNN - Deep neural network

EBGM - Elastic Bunch Graph Matching

GMM - Gaussian Mixture Model

GUI - Graphical User Interface

HCI - Human-Computer Interaction

HoG - Histogram of oriented gradients

SVM - Support-vector machine

VAD - Voice Activity Detection

VVAD - Visual Voice Activity Detection

## 2 Teoretický prehľad

### 2.1 Human-Computer Interaction

HCI - Human-Computer Interaction (interakcia človek počítač), je medziodbo-rová disciplína, ktorá skúma problematiku interakcie a komunikácie medzi človekom a počítačom. Vznikla na prelome 70. a 80. rokov dvadsiateho storočia, v dobe, keď začali vznikať prvé osobné počítače. HCI v sebe spája veľa oborovPOZNodborov?, ktoré na prvý pohľad nemajú nič spoločné. Ak sa však chceme zaoberať vytváraním používateľských rozhraní, kľúčové sú nasledujúce disciplíny: informatika, ergonómia, umenie, design, psychológia, kognitívna psychológia, lingvistika, sociológia, filozofia, antropológia, fyziológia, umelá inteligencia, inžinierstvo, kognitívna veda, etika, estetika a. i.

Informatika sa v oblasti HCI zameriava najmä na design a tvorbu informačných systémov a ich rozhraní tak, aby boli čo najjednoduchšie a najintuitívnejšie pre špecifickú skupinu používateľov. HCI skúma aj vnímanie, správanie a informačné potreby koncového používateľa. Hlavným cieľom HCI je dosiahnuť lepšiu použiteľnosť a intuitívnosť informačných systémov aj pre menej odborných používateľov. [13]

### 2.2 Vývoj HCI

V tejto časti popíšeme historický vývoj komunikácie medzi človekom a počítačom.

#### 2.2.1 CLI

Od polovice 60. rokov sa CLI - Command-Line Interface (príkazový riadok) používa ako hlavný spôsob komunikácie človeka s počítačom. Používateľ zadáva príkazy pomocou klávesnice, výsledky vidí na monitore väčšinou v textovej podobe. Používanie CLI pokračuje v 70. a 80. rokoch systémoch OpenVMS, Unix a osobných počítačoch MS-DOS, CP/M a Apple DOS. Pre skúseneho používateľa má CLI veľa výhod, uvedieme niektoré z nich:

- rýchlosť a efektívnosť,
- možnosť použitia skriptov,
- história príkazov,
- nie je potrebná myš, stačí klávesnica,...

Ale pre menej skúseného používateľa prináša veľa nevýhod, napríklad:

- prostredie je veľmi neintuitívne a striktné,
- nemožnosť použitia myši, ...

Aj v dnešnej dobe je CLI často používané, najmä medzi používateľmi linuxu, na spravovanie serverov a podobne.

### 2.2.2 GUI

S príchodom väčšieho grafického výkonu vzniká GUI - Graphical User Interface (Grafické používateľské rozhranie). Okrem klávesnice sa používa počítačová myš a vznikajú okná. Oproti CLI má GUI veľké výhody pre neskúseného používateľa:

- intuitívnosť,
- rýchlosť - v špecifických prípadoch (napr. presúvanie súborov), ...


Často ale môže nastať prípad, keď sú niektoré nastavenia príliš hlboko v systéme a pomocou GUI sa k nim nie je možné dostať. V dnešnej dobe je GUI najpoužívanejším typom HCI na osobných počítačoch.

### 2.2.3 NUI


S príchodom nových technológií (smartrfónov, virtuálnej reality, ...) sa do popredia začína dostávať NUI - Natural User Interface (Prirodzené používateľské rozhranie). Pomocou NUI dokáže používateľ úplne prirodzene, priamo a intuitívne interagovať s počítačom. Príkladom NUI, s ktorým sa už asi každý stretol, je používanie gest na dotykových obrazovkách. Ďalšie príklady NUI je možné vidieť na nasledujúcich obrázkoch 1, 2 a 3.



Obr. 1: Google Home - Inteligentný domáci asistent, s ktorým sa komunikuje pomocou hlasových príkazov. Zdroj: [2].



Obr. 2: Manipulácia objektov pomocou optickej pinzety, kontrolovaná pozíciou prstov. Zdroj: [20].



Obr. 3: Používanie aplikácie Calcflow vo virtuálnej realite. Zdroj: [12].

### 3 Motivácia a ciele

Jedným z hlavných motívov, prečo vznikla táto práca bola nasledujúca situácia.

Predstavme si situáciu konferenčného hovoru. Jeden z účastníkov potrebuje niečo urobiť, no jeho aktivita by bola hlučná, čím by rušil ostatných účastníkov a teda si vypne mikrofón. Samozrejme, neskôr keď chce niečo povedať, nezapne mikrofón a ostatní ho nepočujú.


Ako by sme sa mohli popísanej situácii vyhnúť? Čo tak zapínať a vypínať mikrofón automaticky podľa toho, či človek sediaci pred kamerou rozpráva alebo nerozpráva. Jedným z riešení by mohla byť detekcia reči (Voice activity detection - VAD) pomocou mikrofónu (Acoustic Voice Activity Detection - AVAD). Toto riešenie však nemusí byť najpresnejšie, napríklad by nemuselo detegovať tichý hlas alebo by detegovalo nechcený šum a podobne. Vhodným zlepšením by mohlo byť zlúčenie AVAD s VAD pomocou obrazu webovej kamery (Visual Voice Activity Detection - VVAD). Naštudovali sme niekoľko existujúcich riešení, ktoré sú popísané v nasledujúcej kapitole.

Ďalším krokom pri vypracovávaní tejto práce, bude implementovanie vlastného riešenia VAD inšpirovaného existujúcimi riešeniami a snaha o jeho implementáciu do existujúceho videokonferenčného systému.

## 4 Riešenia VAD

V nasledujúcich odsekoch ukážeme niekoľko existujúcich riešení. Zameriame sa na použité technológie, dosiahnuté výsledky a problémy, ktoré majú uvedené riešenia.


V [1] riešia VAD u šoféra v aute. Reč detegujú zo zvuku pomocou Gaussian mixture model (GMM). Túto detekciu kombinujú s VVAD. Kvôli odfiltrovaní nepriaznivých odleskov a nedostatku svetla v noci používajú infračervenú kameru. Z šedo-tónového obrazu získavajú obrysy pier, pomocou Elastic Bunch Graph Matching (EBGM). Ukážku získaného obrysu pier je možné vidieť na 4.



Obr. 4: Získavaný obrys pier pomocou EBGM. Zdroj: [1].

Z pier určujú pomer ich výšky a šírky. Získaný pomer má výhodu v nezávislosti od vzdialenosti tváre od kamery. Obrázok 5 vysvetľuje prečo sa pomer mení, len keď človek rozpráva.





Obr. 5: Pomer výšky a šírky pier sa zmení len keď sa ústa otvárajú a zatvárajú. Zdroj: [1].


Navrhnutú metódu testovali tak, že šofér (raz muž a raz žena) prečítal 100 názvov japonských miest. Testovaná metóda priemerne zlepšuje detekciu reči o 40% oproti použitiu len AVAD. Získane výsledky možno vidieť v tabuľke 1.

	Všetky zdetegovania reči	Správne zdetegovania reči	Úspešnosť	Presnosť
muž	106	100	100%	94,33%
žena	118	100	100%	84,75%

Tabuľka 1: Výsledky testovania metódy v práci [1].

Nevýhodou metódy je to, že funguje len pri pohľade spredu. V článku sa nepíše nič o rýchlosti ich riešenia.

V [21] sa zaoberajú detegovaním reči z jednoduchšej webovej kamery. Najprv orežú snímky videa na oblasť pier. Snímky prevedú do šedotónovej oblasti, vyrežú 200 náhodných oblastí a urobia rozdiel všetkých snímok a prvého. Takto vedia modelovať zmeny vo vzhľade podľa rozdielov v čase. Z každého rozdielu počítajú štatistické koeficienty priemer, smerodajnú odchýlku a priemer nad prvou deriváciou. Aplikovaním popísaného postupu vytvorili tréningovú množinu o veľkosti 130000. Následne natrénovali klasifikátor Random Forest s veľkosťou 20 stromov a maximálnou hĺbkou 10. Random Forest porovnávali s klasifikátorom Random Ferns. Random Ferns dosahovali pri rôznych nastaveniach parametrov stále horšie výsledky ako Random Forests. Porovnanie týchto dvoch metód je na obrázku 6.



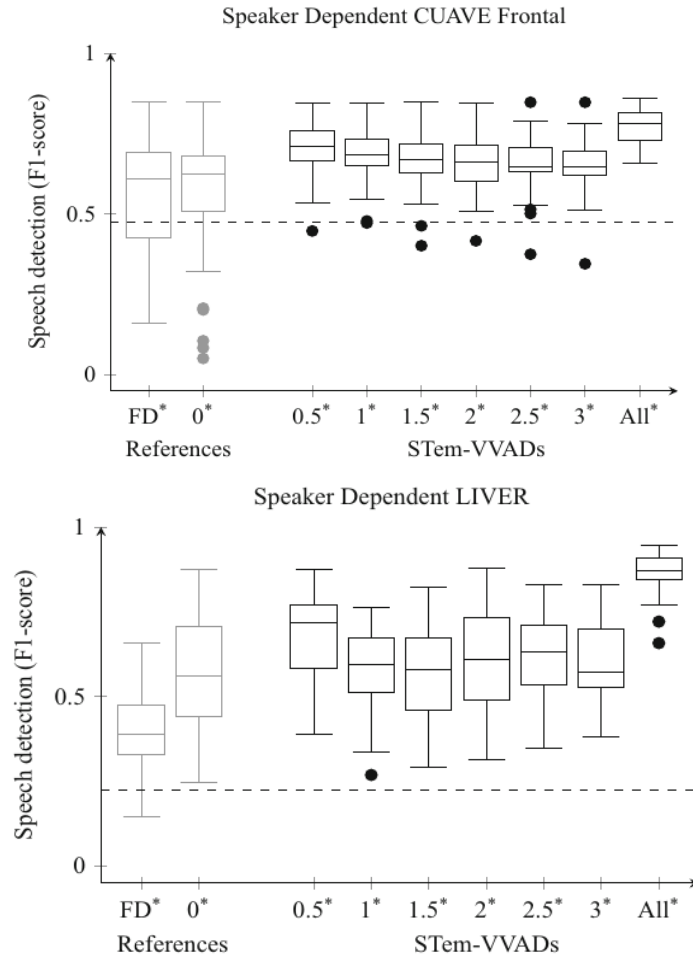
Obr. 6: Porovnanie klasifikátorov Random Forest a Random Ferns. Zdroj: [21].

Podľa článku navrhnutá metóda používa pohľad na tvár spredu a je použiteľná v reálnom čase (30 fps), kvôli rýchlosti výpočtu Random Forest.

V článku [7] popisujú a testujú metódu VVAD založenú na Spatiotemporal Gabor filters, ktorá podľa autorov nebola nikdy predtým na VVAD použitá. Používajú dva datasety: CUAVE - obsahuje nahrávky reči pri pohľade spredu aj z profilu a LIVER - obsahuje nahrávky vyslovovania holandského slova "liver" pri pohľade spredu. Ich metóda sa skladá z 2 fáz:

- fáza predspracovania - aplikovanie Spatiotemporal Gabor filters na zistenie energií v konkrétnych rýchlostiach (jeden z parametrov Spatiotemporal Gabor filters),
- agregáčn a klasifikačná fáza vytvárajúca sumáciu a klasifikátor, na priradzovanie agregovaných energetických hodnôt do binárnych tried (SPEECH a NON-SPEECH).

Nimi navrhnutú metódu porovnávajú s 2 referenčnými metódami - metódou založenou na rozdieloch snímok a metódou založenou na štandardných Gabor filters. Ich metóda bola v skoro všetkých prípadoch lepšia ako referenčné metódy. Niektoré porovnania je možné vidieť na obrázku 7.



Obr. 7: Porovnanie referenčných metód založených na rozdieloch snímok (FD\*) a štandardných Gabor filters (0\*) s metódou založenou na Spatiotemporal Gabor filters s rôznymi parametrami rýchlosti (0,5\*, 1\*, 1,5\*, 2\*, 2,5\*, 3\*, All\*). Zdroj: [7].

Metóda z článku [7] funguje pri pohľade spredu aj z profilu. V článku sa nepíše nič o rýchlosti ich riešenia.

## 5 Návrh riešenia

Po preštudovaní uvedených článkov, sa ako najpoužiteľnejšie riešenie pre VVAD javí sledovať zmeny pohybu pier popísanú v článku [1]. V článku sa nepíše nič o rýchlosti ním vytvoreného riešenia EBGM na detekciu pier v obraze a riešenie asi nebude fungovať v reálnom čase. Naše riešenie bude musieť v reálnom čase fungovať, keďže zapínanie a vypínanie mikrofónu pri videohovore si to vyžaduje. V nasledujúcej časti opíšeme články zaoberajúce sa detekciou bodov na tvári.


### 5.1 Detekcia bodov na tvári - VVAD

V článku [15] prezentujú algoritmus na simultánnu detekciu tváří, bodov na tvári, pozíciu (otočenie) tváre (hlavy) a rozoznávanie pohlavia s použitím DCNN. Uvádzajú dve verzie ich algoritmu nazývaného HyperFace:

- HyperFace-ResNet, ktorý je postavený na modeli ResNet-101 a prináša značné zlepšenie výkonu algoritmu,
- Fast-HyperFace, ktorý používa rýchlejší detektor tváří na zrýchlenie algoritmu.

Na obrázku 8 je architektúra siete HyperFace.





Obr. 10: Testovacie výsledky algoritmu používajúceho náhodné regresné stromy na nájdenie 194 bodov na tvári. Zdroj: [8].

Pre náš problém sa javí riešenie z článku [8] ako lepšie, keďže už názov článku hovorí o jeho rýchlosti (One millisecond face alignment with an ensemble of regression trees). Ďalšou výhodou tohoto riešenia je to, že je implementované v knižniciach Dlib a OpenCV.


(K tomuto článku budem neskôr chcieť spísať matematiku, keďže ho v diplomke najviac používam)

## 5.2 Existujúce implementácie

V tejto podkapitole popíšeme existujúce knižnice (implementácie), ktoré sa zaoberajú detekciou tváre a bodov na nej.

### 5.2.1 Intel RealSense

V roku 2018 predstavil Intel prvé hĺbkové kamery RealSense. K týmto kamerám vydal SDK [5] pre operačný systém Windows. Toto SDK dokázalo v obmedzenej miere pracovať aj s bežnou webovou kamerou. Dostupná bola pre nás dôležitá funkcia detekcie bodov na tvári. Ukážka funkcionality SDK je na obrázku 11.



Obr. 11: Prvé SDK k Intel RealSense dokázalo sledovať ruku a prsty, analyzovať tvár, rozpoznávať reč a. i. Zdroj: [5].


Existujú 2 dôvody, prečo toto riešenie nie je pre nás vhodné:

- podporovaný bol len operačný systém Windows - naše riešenie má byť multiplatformové,
- vývoj SDK bol zastavený.

Toto SDK bolo nahradené novým multiplatformovým SDK [6], ktoré už ale nevie pracovať s bežnou webovou kamerou.

### 5.2.2 Knižnica OpenCV


OpenCV[14] (Open Source Computer Vision Library) je multiplatformová knižnica zameraná na počítačové videnie. V knižnici OpenCV je implementovaná detekcia tvárí a aj detekcia bodov na tvári z článku [8]. Prečo nepoužijeme knižnicu OpenCV si popíšeme v kapitole 5.2.4. Ukážku detekcie je možné vidieť na obrázku 12.



Obr. 12: Ukážka výsledku detekcie bodov na tvári pomocou knižnice OpenCV. Zdroj: [14].

### 5.2.3 Knižnica Dlib

Dlib[9] je moderná multiplatformová knižnica obsahujúca nástroje pre strojové učenie a vytváranie komplexného softvéru v jazyku C++. Ako sme spomínali v predchádzajúcej podsekcii v knižnici Dlib je implementovaná detekcia bodov na tvári z článku [8]. Ukážka detekcie bodov na tvári pomocou knižnice Dlib je na obrázku 13.



Obr. 13: Detekcia detekcie 68 bodov na tvári pomocou knižnice Dlib. Zdroj: [10].

### 5.2.4 Porovnanie knižníc OpenCV a Dlib

V oboch knižniciach je implementovaná detekcia bodov na tvári z článku [8]. Ako problém ostáva nájdenie tváre v obraze. Obe knižnice ponúkajú viacero metód, ktoré tento problém riešia. Na stránke [3] porovnávajú metódy detekcie tváre v knižniciach OpenCV a Dlib. Zameriavajú sa na 4 nasledujúce metódy:

- detekcia tváre pomocou Haar Cascade - OpenCV,
- detekcia tváre pomocou DNN - OpenCV,
- detekcia tváre pomocou HoG - Dlib,
- detekcia tváre pomocou CNN - Dlib.

Popíšeme výhody a nevýhody jednotlivých metód.

Detekcia tváre pomocou **Haar Cascade - OpenCV** bola špičkovou od roku 2001, kedy bola predstavená výskumníkmi Viomom a Jonesom.

Výhody:

- funguje takmer v reálnom čase na CPU,



- jednoduchá architektúra,
- deteguje tváre rôznych veľkostí.

Nevýhody:

- deteguje veľa objektov, ktoré nie sú tvármi,
- nefunguje na tvárach, ktoré nie sú pri pohľade spredu,
- Nefunguje ani pri čiastočnom zakrytí tváre.

Detekcia tváre pomocou **DNN** je v OpenCV implementovaná od verzie 3.3.

Výhody:

- najpresnejšia zo štyroch uvedených metód,
- funguje v reálnom čase na CPU,
- rozpozná rôzne otočené tváre,
- funguje aj pri značnom zakrytí tváre,
- deteguje tváre rôznych veľkostí.

Nevýhody:

- žiadne, až na tú, že nasledujúca metóda je rýchlejšia.

Detekcia tváre pomocou **HoG** je široko používaný model v knižnici Dlib založený na HoG a SVM.

Výhody:

- najrýchlejšia zo štyroch uvedených metód na CPU,
- funguje veľmi dobre pri pohľade na tvár spredu a mierne zboka,
- jednoduchý a nenáročný model v porovnaní s ostatnými,
- funguje pri čiastočnom zakrytí tváre.

Nevýhody:

- hlavná nevýhoda je, že metóda nedeteguje malé tváre (cca. 80x80 pixelov),

- box ohraničenia tváre často vynecháva čelo a bradu,
- nefunguje dobre pri značnom zakrytí tváre,
- nefunguje pre pohľad zboka a pre pohľad hore a dole.

Detekcia tváre pomocou **CNN** v knižnici Dlib používa Maximum-Margin Object Detector s CNN.


Výhody:

- funguje pre rôzne orientácie tváre,
- metóda je robustná na zakrytie tváre,
- funguje veľmi rýchlo na GPU.

Nevýhody:

- metóda je veľmi pomalá na CPU,
- metóda natrénovaná na detekciu tvári väčších ako 80x80 pixelov,
- box ohraničenia tváre je ešte menší ako v predchádzajúcom prípade.

Pre naše potreby je najvhodnejšia metóda detekcie tváre pomocou HoG implementovaná v knižnici Dlib. Táto metóda nie je najpresnejšia, ale keďže chceme rozpoznávať reč pri videohovore, môžeme predpokladať, že vo väčšine prípadov sa osoba pred kamerou bude pozeráť priamo na kameru (monitor) a tvár nebude mať ničím zakrytú. To, že metóda má problém s malými tvármi tiež pre nás nie je problém, lebo pri videohovore predpokladáme, že tvár nebude ďaleko od kamery. Zo spomínaných metód je jednoduchá, nenáročná a na CPU najrýchlejšia, čo je veľmi dobré, lebo kladieme veľký dôraz na to, aby naše riešenie fungovalo v reálnom čase. Porovnanie rýchlosti jednotlivých metód je uvedené na obrázku 14.




Obr. 14: Porovnanie rýchlosti štyroch popísaných metód. Zdroj: [3].

### 5.3 Detekcia reči zo zvuku - AVAD

Detekcia reči z videa nemusí byť pre naše potreby dostatočná. V nasledujúcej časti si popíšeme prácu zaoberajúcu sa detekciou reči zo zvuku.

V práci [11] predstavujú takmer ideálny AVAD algoritmus, ktorý je ľahký na implementáciu a robustný vzhľadom na šum. Pri detekcii využívajú 3 rozdielne vlastnosti pre každú zvukovú snímku: energiu, spektrálnu rovinnosť (Spectral Flatness) a najdominantnejšiu frekvenčnú zložku. Pre každú z týchto vlastností sa zvolí prah a pre každú zvukovú snímku sa rátajú tieto 3 vlastnosti. Ak hodnota ktorejkoľvek vlastnosti bude väčšia ako prah prehlási sa aktuálna zvuková snímka za snímku s rečou. Prahy sa dynamicky menia počas behu algoritmu vzhľadom na predchádzajúce zvukové snímky. Ukážka vypočítaných vlastností na zvukovom súbore pomocou algoritmu z [11] je na obrázku 15.



Obr. 15: Ukážka vypočítaných vlastností na zvukovom súbore bez šumu. Zdroj: [11].

## 5.4 VAD spojením AVAD a VVAD a vytvorenie knižnice

Výstupom tejto diplomovej práce by mal program schopný zistiť, či používateľ počas videohovoru rozpráva alebo nerozpráva. Na to chceme použiť kombináciu metód VVAD a AVAD. Kombinácia metód je dôležitá v rôznych prípadoch. AVAD je dôležitá keď používateľ nemá webovú kameru, nie je ho na obraze vidieť, v miestnosti je zlé svetlo a. i. VVAD je dôležitá v prípade nemožnosti detekcie zo zvuku, napríklad kvôli šumu alebo rušivému rozprávaniu inej osoby.

Výstup z práce by mal mať formu dynamickej multiplatformovej C++ knižnice. V knižnici by mala byť implementovaná funkcia, ktorej vstupom by mali byť dve polia. Jedno pole s video snímkou a druhé so zvukovou snímkou. Výstup funkcie by mal závisieť od vstupných polí nasledovne:

- ak sú obe polia nenulové, funkcia by mala vrátiť či bola detegovaná reč, či bola detegovaná zo zvuku alebo videa, pozíciu tváre ak bola detegovaná, a. i.,
- ak je pole so zvukovou snímkou nulové a s video snímkou nenulové, či bola detegovaná reč z videa, pozíciu tváre ak bola detegovaná, a. i.,
- ak je pole so zvukovou snímkou nenulové a s video snímkou nulové, či bola detegovaná reč zo zvuku, a. i.

Takýmto spôsobom môže byť využitie knižnice väčšie. Napríklad v prípade nedetegovania tváre sa môže znížiť kvalita prenášaného obrazu pri videohovore, čím sa zníži záťaž procesora aj sieťovej linky.

## 6 Implementácia a testovanie

V tejto kapitole popíšeme implementáciu nami navrhnutého riešenia VAD v C++ knižnici.

### 6.1 Použitý hardware a software

Implementácia a testovanie prebiehali na notebooku Asus Zenbook UX305FA (Intel Core M 5Y10, 8GB RAM). Pre testovanie sme používali webovú kameru LifeCam Cinema. Vyvíjali sme jazyku C++, ktorý je najvhodnejší pre prácu s videom. Používali sme knižnice OpenCV, Dlib, SFML. Ako vývojárske prostredie bol zvolený CLion a buildovali sme pomocou Cmake.

### 6.2 Implementácia VVAD

Vytvorili sme dynamickú knižnicu s názvom VVAD. V hlavičkovom súbore `VVAD.h` sa nachádzajú definície tried, metód a premenných definovaných v súbore `VVAD.cpp`. V hlavičkovom súbore sú definované 2 triedy: `VVAD` a `Output`. Trieda `VVAD` je hlavnou triedou, ktorá obsahuje verejne metódy:

- `Frame` - hlavná metóda, ktorej vstupom je video snímok a výstupom je objekt triedy `Output`.
- `FrameForLearningThreshold` - metóda sa volá na začiatku používania knižnice na určenie prahu. Vstupom metódy je video snímok a výsledným výstupom je prah, pomocou ktorého metóda `Frame` vyhodnocuje, či vo videosekvencii nasala reč alebo nie.
- `SaveThreshodToFile` - metóda uloží prah do súboru určeného reťazcom, ktorý dostane na vstup.
- `LoadThresholdFromFile` - metóda načíta prah zo súboru určeného reťazcom, ktorý dostane na vstup.

- `getThreshold` - vráti hodnotu prahu.
- `setThreshold` - nastaví hodnotu prahu.
- `isCalibrated` - vráti pravdivostnú hodnotu, ktorá hovorí, či prah bol nastavený.
- `getCalibrated` - nastaví pravdivostnú hodnotu, ktorá hovorí, či prah bol nastavený.

V nasledujúcej časti popíšeme fungovanie niektorých metód detailne.

## 6.2.1 Metóda Frame

### 6.2.1.1 Detekcia tváre pomocou knižnice Dlib

Ako sme popísali v časti 5.2.4, na detekciu tváre sme použili knižnicu Dlib, konkrétne detekciu tváre pomocou HoG. Táto detekcia je najpomalšia časť celého algoritmu, no aj napriek tomu funguje dostatočne rýchlo na oboch počítačoch, ktoré sme pri implementácii používali. Dôvodom je to, že predtým Tvár sa po nájdení v obraze posielala na

### 6.2.1.2 Vytvorenie modelu pre detekciu bodov na tvári

Pre detekciu bodov na tvári budeme potrebovať natrénovaný model. V príkladových súboroch knižnice sa nachádzajú aj 2 predtrénované modely, ktoré detegujú 68 alebo 5 bodov na tvári. Model so 68 bodmi má približne 95MiB, čo je príliš veľa a model s 5 bodmi zas neobsahuje body na perách. Rozhodli sme sa teda vytvoriť vlastný model, ktorý by mal menšiu veľkosť a bol dostatočne presný pre naše potreby. Pre trénovanie modelu budeme potrebovať fotografie osôb a k nim súbor formátu xml, v ktorom budú uložené polohy jednotlivých bodov na tvárach ľudí na fotografiách. V príkladových súboroch sa nachádzajú fotografie aj xml súbory pomocou ktorých je možné trénovať model. Na trénovanie sú určené 4 fotografie s celkovo 18 tvármi. Na testovanie je určených 5 fotografií s celkovo 25 tvármi. Pomocou uvedených súborov však nie je možné natrénovať dostatočne presný model. Zo stránky [4] sme získali dataset 300-W (pri použití daného datasetu žiadajú na stránke citovať [16], [17] a [18]) obsahujúci fotografie z datasetov afw, helen, ibug a lfpw. Dataset samozrejme obsahoval aj testovací a trénovací xml súbor s označenými umiestneniami 68 bodov na tvári, pomocou ktorých je možné natrénovať presnejší model. Trénovací súbor obsahoval 6666 tvári a testovací obsahoval 1008 tvári. Knižnica Dlib obsahuje nástroj na vytváranie a úpravu xml súborov s informáciami o bodoch na tvárach na fotografiách a aj nástroj na trénovanie a testovanie modelu na základe fotografií a xml súborov. Pomocou nástroja na prácu s

xml súbormi z knižnice Dlib a editora Sublime Text sme upravili počet bodov na tvári v xml súboroch. ... Nástroj na tréovanie má možnosť nastaviť parametre tréovania, ako je napríklad hĺbka stromu a. i. (POPIŠ VIAC) Vytvorili sme 2 nové modely, úpravou xml súborov pre 68 bodový model, odstránením niektorých bodov:

- 20 bodový model pier. Ponechali sme len body na perách. Výsledný model mal menej ako 5MiB. Model ale nebol dostatočne presný.
- 27 bodový model pier. Kvôli zvýšeniu presnosti modelu sme okrem 20 bodov na perách nechali body na spodnej časti uší, bod na brade, nose, medzi očami a vonkajšie krajné body očí. Ani tento model nebol dostatočne presný.

Keďže sa nám zatiaľ nepodarilo vytvoriť vhodnejší model používali sme 68 bodový model. (Musím viac pochopiť článok aj implementáciu a potom skúsím vytvoriť lepší model) Ukážka detekcie modelu so 68 bodmi v obraze z webovej kamery je na obrázku 16.




Obr. 16: Ukážka detekcie modelu so 68 bodmi v reálnom čase pomocou knižnice Dlib.

### 6.2.2 VVAD

Podľa práce [1] potrebujeme získať pomer výšky a šírky pier. Do pomocného poľa si z všetkých bodov tváre uložíme 6 bodov pier: bod z pravej a z ľavej strany, 2 body z hornej a 2 body z dolnej časti pier. (tu by sa hodil obrázok) Výšku pier rátame ako vzdialenosť priemeru 2 bodov z hornej a 2 bodov z dolnej časti pier a šírku pier rátame ako vzdialenosť bodu z pravej a z ľavej strany pier. Do 10 prvkového poľa si ukladáme hodnoty rozdielu pomerov medzi dvoma po sebe nasledujúcimi rátaniami pomeru. Ako toto 10 prvkové pole funguje, je vysvetlené na obrázku 17. Ak sa v poli nachádza hodnota väčšia ako zvolený prah, vyhlásime program vyhlási, že osoba rozpráva, inak


nerozpráva. Pri testovaní nám vychádza najlepšie, ak rátame pomer každých minimálne 50 milisekúnd. Tým je zabezpečené to, že pomer sa neráta viac ako 20 krát za sekundu a teda výstup programu bude stálejší v čase.



Obr. 17: Vysvetlenie posuvného poľa použitého pri navrhnuťej metóde VVAD. Pri zrátaní nového pomeru sa posunú hodnoty v poli a nová hodnota sa vloží na prázdne miesto. Takto si pamätáme posledných 10 rozdielov pomerov.


Navrhnutú metódu sme testovali na viacerých videách s rozprávacou osobou. Po niekoľkých videách sme odhadli vhodnú hodnotu prahu. Takto zvolený prah však nemusí vždy správne určiť, či prebieha reč alebo nie. (prah asi bude dobre upravovať v case - to este musim domysliet) Na obrázku 18 je graf rozdielu pomerov, prislúchajúci videu, kde osoba na začiatku rozprávala a ku koncu nie. V tomto prípade navrhnutá metóda správne vyhodnotila priebeh reči.





Obr. 18: Korektná detekcia reči pomocou navrhnutej metódy VVAD. Červené body sú absolútna hodnota rozdielov pomerov 2 po sebe idúcich meraní. Modrá čiara vo výške 0,6 znamená, že reč bola detekovaná a vo výške 0,3, že nebola detekovaná.

Na obrázku 19 je graf rozdielu pomerov, prislúchajúci videu s inou osobou, ktorá na začiatku nerozprávala, potom rozprávala a ku koncu opäť nerozprávala. Približne v strede grafu je modrá čiara na úrovni 0,3, čo znamená, že metóda vyhodnotila túto časť videa ako časť kde osoba nerozpráva, čo nie je korektné.



Obr. 19: Nepresná detekcia reči pomocou navrhnutej metódy VVAD. Červené body sú absolútna hodnota rozdielov pomerov 2 po sebe idúcich meraní. Modrá čiara vo výške 0,6 znamená, že reč bola detekovaná a vo výške 0,3, že nebola detekovaná.

## 6.3 Implementácia AVAD

Pri implementovaní AVAD sme používali knižnicu SFML [19]. Pracuje sa na tom...

# Zoznam použitej literatúry

- [1] AOKI, M., MASUDA, K., MATSUDA, H., TAKIGUCHI, T., AND ARIKI, Y. Voice activity detection by lip shape tracking using ebkm. In *Proceedings of the 15th ACM international conference on Multimedia* (2007), ACM, pp. 561–564.
- [2] GOOGLE. Google home. Dostupné na internete: [https://store.google.com/us/product/google\\_home?hl=en-US](https://store.google.com/us/product/google_home?hl=en-US). [cit. 21. 1. 2019].
- [3] GUPTA, V. Face detection – opencv, dlib and deep learning ( c++ / python ). Dostupné na internete: <https://www.learnopencv.com/face-detection-opencv-dlib-and-deep-learning-c-python/>. [cit. 21. 1. 2019].
- [4] IBUG. 300 faces in-the-wild challenge (300-w), imavis 2014. Dostupné na internete: [https://ibug.doc.ic.ac.uk/resources/300-W\\_IMAVIS/](https://ibug.doc.ic.ac.uk/resources/300-W_IMAVIS/). [cit. 21. 1. 2019].
- [5] INTEL. Intel® realsense sdk for windows\* (discontinued). Dostupné na internete: <https://software.intel.com/en-us/realsense-sdk-windows-eol>. [cit. 21. 1. 2019].
- [6] INTEL. Intel® realsense™ sdk 2.0. Dostupné na internete: <https://realsense.intel.com/sdk-2/>. [cit. 21. 1. 2019].
- [7] JOOSTEN, B., POSTMA, E., AND KRAHMER, E. Voice activity detection based on facial movement. *Journal on Multimodal User Interfaces* 9, 3 (2015), 183–193.
- [8] KAZEMI, V., AND SULLIVAN, J. One millisecond face alignment with an ensemble of regression trees. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition* (2014), pp. 1867–1874.
- [9] KING, D. Dlib. Dostupné na internete: <http://dlib.net/>. [cit. 21. 1. 2019].
- [10] MALLICK, S. Facial landmark detection. Dostupné na internete: <https://www.learnopencv.com/facial-landmark-detection/>. [cit. 21. 1. 2019].

- [11] MOATTAR, M. H., AND HOMAYOUNPOUR, M. M. A simple but efficient real-time voice activity detection algorithm. In *Signal Processing Conference, 2009 17th European* (2009), IEEE, pp. 2549–2553.
- [12] NONAME. Calcflow. Dostupné na internete: <http://calcflow.io/>. [cit. 21. 1. 2019].
- [13] NĚMEČKOVÁ, L. Rozvoj problematiky hci (human-computer interaction) na Úisk ff uk. Dostupné na internete: [http://clovek.ff.cuni.cz/pdf/nemeckova\\_zprava\\_18.pdf](http://clovek.ff.cuni.cz/pdf/nemeckova_zprava_18.pdf), 2010. [cit. 21. 1. 2019].
- [14] OPENCv. opencv. Dostupné na internete: [https://docs.opencv.org/4.0.1/d2/d42/tutorial\\_face\\_landmark\\_detection\\_in\\_an\\_image.html](https://docs.opencv.org/4.0.1/d2/d42/tutorial_face_landmark_detection_in_an_image.html). [cit. 21. 1. 2019].
- [15] RANJAN, R., PATEL, V. M., AND CHELLAPPA, R. Hyperface: A deep multi-task learning framework for face detection, landmark localization, pose estimation, and gender recognition. *IEEE Transactions on Pattern Analysis and Machine Intelligence* (2017).
- [16] SAGONAS, C., ANTONAKOS, E., TZIMIROPOULOS, G., ZAFEIRIOU, S., AND PANTIC, M. 300 faces in-the-wild challenge: Database and results. *Image and vision computing* 47 (2016), 3–18.
- [17] SAGONAS, C., TZIMIROPOULOS, G., ZAFEIRIOU, S., AND PANTIC, M. 300 faces in-the-wild challenge: The first facial landmark localization challenge. In *Proceedings of the IEEE International Conference on Computer Vision Workshops* (2013), pp. 397–403.
- [18] SAGONAS, C., TZIMIROPOULOS, G., ZAFEIRIOU, S., AND PANTIC, M. A semi-automatic methodology for facial landmark annotation. In *Proceedings of the IEEE conference on computer vision and pattern recognition workshops* (2013), pp. 896–903.
- [19] SFML. SfmL - simple and fast multimedia library. Dostupné na internete: <https://www.sfmL-dev.org/>. [cit. 21. 1. 2019].
- [20] TOMORI, Z. Microrobotics. Dostupné na internete: <http://home.saske.sk/~tomori/tweezers.htm>. [cit. 21. 1. 2019].
- [21] VIERIU, L. Real-time voice activity detection using a simple webcam. *Proceedings of WCSIT* (2014).